

# 전통적 머신러닝 알고리즘 심화

[이론] 김지수 [실습] 강민현, 김준목

{gisookim, mkang, jm0917}@unist.ac.kr

2023년 9월 13일

# 강의 목차

- 1 벡터와 행렬 연산
- 2 간단한 통계량
- 3 확률 분포와 통계적 추론
- 4 선형회귀분석
- 5 로지스틱 회귀분석

# 벡터와 행렬 연산

# 벡터와 행렬

- **배열** (array) : 동일한 특성을 가지는 요소(예: 숫자)가 특정 규칙으로 나열되어 있는 데이터 집합
- **벡터** (vector) : 1차원의 배열.

$$a = [a_1, a_2, \dots, a_n]^T \in \mathbb{R}^n$$

$a_i$ : 벡터  $a$  의  $i$  번째 원소.

- **행렬** (matrix) : 2차원의 (사각형 모양의) 배열. 크기  $n \times m$  인 행렬은  $n$  개의 행(row)과  $m$  개의 열(column)을 가짐.

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1m} \\ a_{21} & a_{22} & a_{23} & \cdots & a_{2m} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{nm} \end{pmatrix} \in \mathbb{R}^{n \times m}$$

$a_{ij}$ : 행렬  $A$ 의  $i$  번째 행,  $j$  번째 열에 위치한 원소.

만약  $n = m$ 이면  $A$ 를 정사각행렬이라 부름.

각 행은 행벡터, 각 열은 열벡터라 부르기도 함.

# 벡터와 행렬 연산

## ① 덧셈 & 뺄셈

$$\begin{pmatrix} 2 & 5 & -1 \\ 1 & 0 & -3 \end{pmatrix} + \begin{pmatrix} -7 & 3 & 1 \\ 4 & 1 & 0 \end{pmatrix} = \begin{pmatrix} -5 & 8 & 0 \\ 5 & 1 & -3 \end{pmatrix}.$$

: 덧셈 & 뺄셈은 크기가 같은 행렬에 대해서만 가능. 원소별로 수행.

## ② 상수 곱

$$3 \times \begin{pmatrix} 2 & 5 & -1 \\ 1 & 0 & -3 \end{pmatrix} = \begin{pmatrix} 6 & 15 & -3 \\ 3 & 0 & -9 \end{pmatrix}$$

## ③ 벡터의 내적

$$a \circ b = a_1b_1 + a_2b_2 + \cdots + a_nb_n = \sum_{i=1}^n a_ib_i$$

# 벡터와 행렬 연산



## 행렬의 곱

$n \times m$  행렬  $A$  와  $m \times p$  행렬  $B$ 를 곱하면  $n \times p$  행렬이 됨:

$$\begin{aligned}
 A \times B &= \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix} \times \begin{pmatrix} b_{11} & b_{12} & \cdots & b_{1p} \\ b_{21} & b_{22} & \cdots & b_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ b_{m1} & b_{m2} & \cdots & b_{mp} \end{pmatrix} \\
 &= \begin{pmatrix} a_{1.} \circ b_{.1} & a_{1.} \circ b_{.2} & \cdots & a_{1.} \circ b_{.p} \\ a_{2.} \circ b_{.1} & a_{2.} \circ b_{.2} & \cdots & a_{2.} \circ b_{.p} \\ a_{3.} \circ b_{.1} & a_{3.} \circ b_{.2} & \cdots & a_{3.} \circ b_{.p} \\ \vdots & \vdots & \vdots & \vdots \\ a_{n.} \circ b_{.1} & a_{n.} \circ b_{.2} & \cdots & a_{n.} \circ b_{.p} \end{pmatrix} (\neq B \times A)
 \end{aligned}$$

example

$$\begin{pmatrix} 2 & 5 & -1 \\ 1 & 0 & -3 \end{pmatrix} \times \begin{pmatrix} 3 \\ 1 \\ 5 \end{pmatrix} = \begin{pmatrix} 6 \\ -12 \end{pmatrix}$$

행렬 곱셈은 (왼쪽 행렬의 열의 개수)=(오른쪽 행렬의 행의 개수) 일때만 가능.

# 벡터와 행렬 연산

## 5 행렬 곱의 성질

$$A(BC) = (AB)C, \quad (A + B)C = AC + BC.$$

## 6 행렬의 전치(Transposition)

$$\begin{pmatrix} 2 & 5 & -1 \\ 1 & 0 & -3 \end{pmatrix}^T = \begin{pmatrix} 2 & 1 \\ 5 & 0 \\ -1 & -3 \end{pmatrix}$$

- 전치는 행렬의 행을 열로 바꿔줌 (=열을 행으로 바꿔줌)
- $(A^T)_{ij} = A_{ji}$
- $n \times m$  행렬의 전치는  $m \times n$  행렬임.
- $(AB)^T = B^T A^T$
- 두 벡터  $a$  와  $b$  의 내적  $a \circ b$  를  $a^T b$  로 표현할 수 있음.

# 특수한 행렬들

- ① **단위 행렬 (Identity matrix)**: 대각 원소가 모두 1이고 비대각 원소가 모두 0인 정사각 행렬.

$$I_2 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad I_n = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}$$

성질 임의의  $n \times m$  행렬  $A$ 에 대하여,  $A \times I_m = I_n \times A = A$  이 성립함.

- ② **대칭 행렬 (Symmetric matrix)**: 대각원소들을 기준으로 대칭을 이루는 행렬. 즉, 정사각 행렬이면서  $A = A^T$ 를 만족하는 행렬  $A$ .

example

$$A = \begin{pmatrix} 3 & 2 & 1 \\ 2 & -5 & 7 \\ 1 & 7 & -4 \end{pmatrix} = A^T$$



## 특수한 행렬들

- ③  $(n \times n)$  정사각 행렬  $A$  에 대하여 아래 식을 만족하는 행렬  $B$ 가 존재하면  $A$ 를 가역(invertible) 행렬이라 함.

$$A \times B = B \times A = I_n$$

$B$ 는  $A$ 의 역행렬이며 ( $B = A^{-1}$ ),  $A$ 도  $B$ 의 역행렬임 ( $A = B^{-1}$ ).

### Notes

- 가역행렬이 아닌 행렬도 존재한다. 예를 들어,  $A = \begin{pmatrix} 1 & 0 \\ 3 & 0 \end{pmatrix}$  는 가역행렬이 아님.
- $2 \times 2$  행렬의 역행렬을 구하는 식:

$$\text{If } A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}, A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

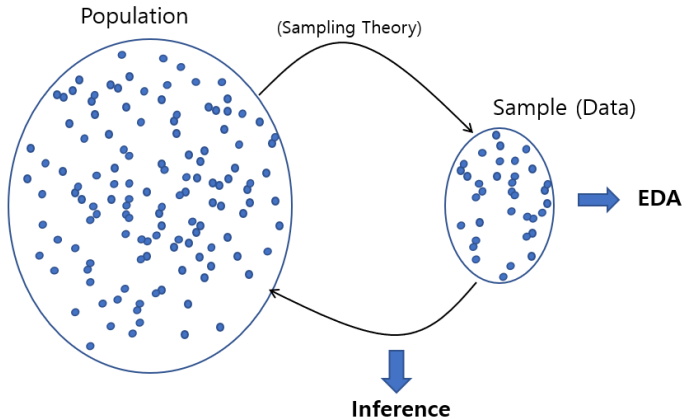
$2 \times 2$  행렬  $A$ 는  $ad - bc \neq 0$ 인 경우에만 가역행렬임.

## 간단한 통계량

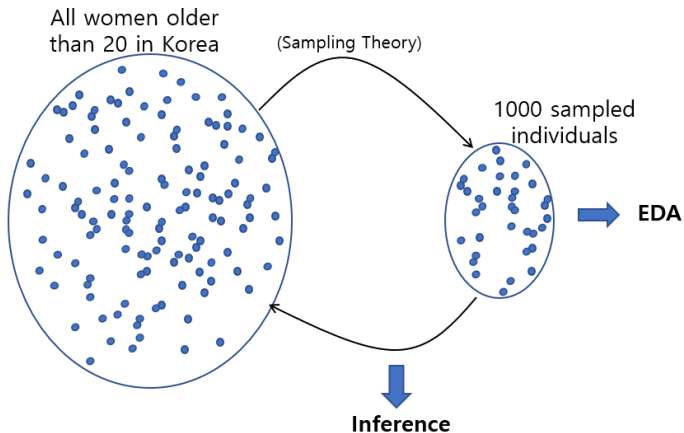
# 통계?

- **통계학**은 관심 모집단으로부터 데이터를 수집하고, 데이터를 과학적으로 분석하고, 데이터로 부터 모집단에 대한 확률론적 추론을 하는 방법론을 통칭함.
- 통계학의 두 갈래:
  - ▷ **탐색적 데이터 분석** (Exploratory Data Analysis; EDA)
  - ▷ **통계적 추론** (Statistical Inference)

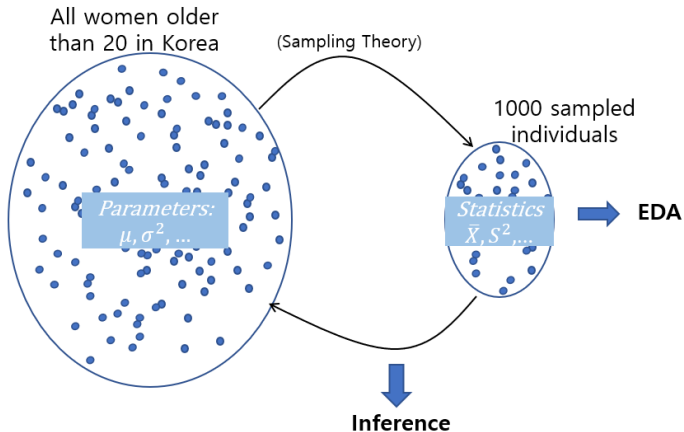
# 통계?



# 통계?



## 통계?



example: 한국의 모든 20세 이상 여성의 평균 키( $\mu$ )에 대한 추론을 하기 위하여 1000명을 추출하고 그들의 평균 키( $\bar{X}$ )를 계산함.

# 중심 경향

- 평균(mean)

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- 중앙값(median)

-변수들을 크기 순서대로 나열한 후 계산:  $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ .

$$\check{X} = \frac{1}{2} \{X_{(\lfloor \frac{n+1}{2} \rfloor)} + X_{(\lceil \frac{n+1}{2} \rceil)}\}$$

어떤 통계량이 더 좋은가?



# 중심 경향

- 평균(mean)

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- 중앙값(median)

-변수들을 크기 순서대로 나열한 후 계산:  $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ .

$$\check{X} = \frac{1}{2} \{X_{(\lfloor \frac{n+1}{2} \rfloor)} + X_{(\lceil \frac{n+1}{2} \rceil)}\}$$

어떤 통계량이 더 좋은가?





# 산포

- 표본 분산

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

$S$ 를 표준편차라 한다.

- 엔트로피

$$\epsilon(X) = - \sum_{c \in \mathcal{C}} \hat{p}_c \log_2 \hat{p}_c.$$

( $\hat{p}_c$ : 데이터 내에서 범주  $c$ 의 비율. )

- $0 \leq \epsilon(X) \leq \log_2(|\mathcal{C}|).$
  - $\epsilon(X) = 0 \Leftrightarrow$  특정 범주  $c$ 에 대하여  $\hat{p}_c = 1.$
  - $\epsilon(X) = \log_2(|\mathcal{C}|) \Leftrightarrow$  모든 범주  $c$ 에 대하여  $\hat{p}_c = 1/|\mathcal{C}|.$
- 그 외 통계량들 : 분위수, 사분위수(Q1: 25% 분위수, Q2: 중앙값, Q3: 75% 분위수), 사분위수 범위(Inter Quartile Range; IQR; Q3-Q1)

# 공변 (Covariation)

- 표본 공분산

$$S_{xy} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$

- 표본 상관계수

$$r_{xy} = \frac{S_{xy}}{S_x S_y} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$


- 두 변수의 선형 관계를 수치화
- $|r| = 1$ 는 완벽한 선형관계를 의미함
- $r = 0$ 는 선형 관계가 없음을 의미
- 부호는 선형관계의 방향을 의미 (양/음의 상관관계)
- $r_{(ax+b)(cy+d)} = r_{xy}$  ( $a, b, c, d \in \mathbb{R}$  and  $ac > 0$ )

# Supplementary: 공분산과 상관계수

공분산 ( $S_{xy}$ )	상관계수 ( $r_{xy}$ )
두 확률 변수가 공변하는 양상을 측정하는 척도	두 확률변수의 선형 관계를 측정하는 척도
단위에 따라 다름	단위가 없음. 단위의 변화에 영향을 받지 않음.
$-\infty \leq S_{xy} \leq \infty$	$-1 \leq r_{xy} \leq 1$

Table: 공분산과 상관계수

# Supplementary: 공분산과 상관계수



**Figure:** Retrieved from <https://statistics.laerd.com/statistical-guides/pearson-correlation-coefficient-statistical-guide.php>

# 통계량의 행렬 연산

평균과 분산, 공분산을 행렬 연산으로 나타내면?

- 평균

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} \mathbf{1} \circ X = \frac{1}{n} \mathbf{1}^T X$$

$$\mathbf{1} = [1, 1, \dots, 1]^T, X = [X_1, X_2, \dots, X_n]^T$$

- 분산

퀴즈!

- 공분산

퀴즈!

# 확률 분포와 통계적 추론

# 확률 분포

모집단(population)은 특정 확률 분포를 따름. 확률 분포는 확률 변수의 값에 따른 확률의 분포를 가리킴.

- 이산형 변수의 **확률 질량 함수**  $p(x)$ :  $p(x) = P(X = x)$ 
  - (1)  $0 \leq p(x) \leq 1$
  - (2)  $\sum_{x \in \mathcal{X}} p(x) = 1.$
  - (3)  $P(a \leq X \leq b) = \sum_{a \leq x \leq b} p(x).$
- 연속형 변수의 **확률 밀도 함수**  $p(x)$ :  $\int_a^b p(x)dx = P(a \leq X \leq b)$ 
  - (1)  $0 \leq p(x)$
  - (2)  $\int_{-\infty}^{\infty} p(x)dx = 1.$
  - (3)  $P(a \leq X \leq b) = P(a < X \leq b) = P(a \leq X < b) = P(a < X < b) = \int_a^b p(x)dx.$

# 모집단의 평균

$$E(X) = \begin{cases} \sum_{x \in \mathcal{X}} xp(x) \\ \int_{-\infty}^{\infty} xp(x)dx \end{cases}$$

$$E(f(X)) = \begin{cases} \sum_{x \in \mathcal{X}} f(x)p(x) \\ \int_{-\infty}^{\infty} f(x)p(x)dx \end{cases}$$

## Properties

- 임의의  $a, b \in \mathbb{R}$ 에 대하여  $E(aX + b) = aE(X) + b$ .
- $E(af_1(X) + bf_2(X)) = aE(f_1(X)) + bE(f_2(X))$ .



# 모집단의 분산

Let  $\mu = E(X)$ .

$$Var(X) = E[(X - \mu)^2] = \begin{cases} \sum_{x \in \mathcal{X}} (x - \mu)^2 p(x) \\ \int_{-\infty}^{\infty} (x - \mu)^2 p(x) dx \end{cases} = E(X^2) - \mu^2$$

$$sd(X) = \sqrt{Var(X)}$$

## Properties

- 임의의  $a, b \in \mathbb{R}$ 에 대하여,  $Var(aX + b) = a^2 Var(X)$ .

# 결합 확률 분포

- 두 이산형 확률변수의 확률 질량 함수:  $p(x, y) = P(X = x, Y = y)$

- (1)  $0 \leq p(x, y) \leq 1$

- (2)  $\sum_{y \in \mathcal{Y}} \sum_{x \in \mathcal{X}} p(x, y) = 1.$

- (3)  $P(a \leq X \leq b, c \leq Y \leq d) = \sum_{c \leq y \leq d} \sum_{a \leq x \leq b} p(x, y).$

- 두 연속형 확률변수의 확률 밀도 함수:

$$\int_c^d \int_a^b p(x, y) dx dy = P(a \leq X \leq b, c \leq Y \leq d)$$

## 주변 분포

- $p_X(x) = \sum_{y \in \mathcal{Y}} p(x, y).$

- $p_X(x) = \int_{-\infty}^{\infty} p(x, y) dy$

# 결합 확률 분포

## 기대값

$$E(f(X, Y)) = \begin{cases} \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} f(x, y) p(x, y) \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) p(x, y) dx dy \end{cases}$$

## 두 확률변수의 독립

임의의 값  $x \in \mathcal{X}$  와  $y \in \mathcal{Y}$ 에 대하여,

$$p(x, y) = p(x)p(y),$$

가 성립하면  $X$ 와  $Y$ 는 독립이다.

두 확률변수  $X$ 와  $Y$ 가 독립이면,

$$\begin{aligned} E(XY) &= \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} xyp(x, y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} xyp(x)p(y) \\ &= \sum_{x \in \mathcal{X}} xp(x) \sum_{y \in \mathcal{Y}} yp(y) = E(X)E(Y). \end{aligned}$$

# 모집단의 공분산과 상관계수

$\mu_X = E(X)$ ,  $\mu_Y = E(Y)$ ,  $\sigma_X = sd(X)$ ,  $\sigma_Y = sd(Y)$ 라 하자.

$$Cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)].$$

$$Corr(X, Y) = E\left[\frac{(X - \mu_X)}{\sigma_X} \frac{(Y - \mu_Y)}{\sigma_Y}\right].$$

# Random sample의 개념

- **Random sample**은 동일한 분포에서 독립적으로 추출한 (identically and independently distributed; i.i.d.) 확률 변수  $X_1, X_2, \dots, X_n$ 의 모음이다. 즉,
  - ①  $X_1, X_2, \dots, X_n$  이 서로 독립이다.
  - ② 임의의  $x \in \mathbb{R}$ 에 대하여  $p(X_1 = x) = p(X_2 = x) = \dots = p(X_n = x)$  .

특정 확률 분포를 가지는 모집단이 있다고 하자. 이 모집단으로 부터 무작위 반복추출로 표본을 추출하면 이 표본이 모집단의 random sample을 이룬다.

Random sample 을 이용하여 모집단에 대한 통계적 추론을 할 수 있다.

# 1. 베르누이 분포

베르누이 분포:  $Ber(p)$  ( $0 < p < 1$ )

- 이항 변수의 분포.

$x$	0	1
$p(x) = P(X = x)$	$1 - p$	$p$

예: 성공/실패, 동전 던질 때의 앞면/뒷면, 질병 진단에 대한 양성/음성 결과, 결혼 여부

- 확률 질량 함수:  $p(x) = p^x(1 - p)^{(1-x)}$ .
- Properties:

$$E(X) = 0 \times (1 - p) + 1 \times p = p$$

$$Var(X) = E[\{X - E(X)\}^2] = E(X^2) - \{E(X)\}^2 = p(1 - p).$$

# 1. 베르누이 분포

베르누이 분포  $Ber(p)$ 를 따르는 모집단으로부터 **random sample**  $X_1, \dots, X_n$ 을 추출하였다고 가정하자. 이 random sample 의 표본 평균은 다음을 만족함을 쉽게 확인 할 수 있다.

- $E(\bar{X}) = p$
- $Var(\bar{X}) = \frac{p(1-p)}{n}$


$\bar{X}$ 의 분포는 ??

$$\begin{aligned}
 P(n\bar{X} = m) &= P(X_1 + X_2 + \dots + X_n = m) \\
 &= \binom{n}{m} p^m (1-p)^{n-m} \\
 &= \frac{n!}{m!(n-m)!} p^m (1-p)^{n-m}
 \end{aligned}$$

## 2. 정규분포

정규분포:  $\mathcal{N}(\mu, \sigma^2)$ .

- 연속형 변수의 분포.



- $x = \mu$ 에 대하여 대칭인 분포.
- 종 모양.
- 산포가  $\sigma$ 에 의해 결정됨.

- 확률 밀도 함수:  $p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$ ,  $-\infty < x < \infty$ .
- Properties:

$$E(X) = \int_{-\infty}^{\infty} xp(x)dx = \mu$$

$$Var(X) = \int_{-\infty}^{\infty} (x - \mu)^2 p(x)dx = \sigma^2$$



## 2. 정규분포

- Properties:

- 임의의  $a, b \in \mathbb{R}$ 에 대하여  $X \sim \mathcal{N}(\mu, \sigma^2)$ 이면,

$$aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2).$$

- $X \sim \mathcal{N}(\mu, \sigma^2)$ 이면,

$$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1) : \text{표준 정규 분포.}$$

- $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$ ,  $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$  이며  $X_1$ 과  $X_2$  과 독립이면, 임의의  $a_1, a_2 \in \mathbb{R}$ 에 대하여,

$$a_1X_1 + a_2X_2 \sim \mathcal{N}(a_1\mu_1 + a_2\mu_2, a_1^2\sigma_1^2 + a_2^2\sigma_2^2).$$

$$\begin{aligned} \text{Var}(a_1X_1 + a_2X_2) &= E[\{(a_1X_1 + a_2X_2) - E(a_1X_1 + a_2X_2)\}^2] \\ &= E[\{a_1(X_1 - \mu_1) + a_2(X_2 - \mu_2)\}^2] \\ &= E[a_1^2(X_1 - \mu_1)^2 + a_2^2(X_2 - \mu_2)^2 + 2a_1a_2(X_1 - \mu_1)(X_2 - \mu_2)] \\ &= a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + 0. \end{aligned}$$

## 2. 정규분포

정규분포  $\mathcal{N}(\mu, \sigma^2)$ 를 따르는 모집단으로부터 **random sample**  $X_1, \dots, X_n$ 을 추출하였다고 가정하자. 이 random sample 의 표본 평균은 다음을 만족함을 쉽게 확인 할 수 있다.

- $E(\bar{X}) = \mu$
- $Var(\bar{X}) = \frac{\sigma^2}{n}$

$\bar{X}$ 의 분포는 ??

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

# 표본 평균의 성질

- 평균이  $\mu$ 이고 분산이  $\sigma^2$ 인 임의의 모집단으로부터 **random sample**  $X_1, \dots, X_n$ 을 추출하였다고 가정하자. 표본 평균  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 의 성질은 아래와 같다.

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} n\mu = \mu.$$

$$\begin{aligned} \text{Var}(\bar{X}) &= E\left[\{\bar{X} - E(\bar{X})\}^2\right] = E\left[\left\{\frac{1}{n} \sum_{i=1}^n X_i - \mu\right\}^2\right] = E\left[\left\{\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} n\mu\right\}^2\right] \\ &= \frac{1}{n^2} E\left[\left\{\sum_{i=1}^n (X_i - \mu)\right\}^2\right] = \frac{1}{n^2} E\left[\sum_{i=1}^n (X_i - \mu)^2 + \sum_{i \neq j} (X_i - \mu)(X_j - \mu)\right] \\ &= \frac{1}{n^2} \left[\sum_{i=1}^n E(X_i - \mu)^2 + \sum_{i \neq j} E[(X_i - \mu)(X_j - \mu)]\right] \\ &= \frac{1}{n^2} \left[n\sigma^2 + \sum_{i \neq j} [E(X_i - \mu)E(X_j - \mu)]\right] = \frac{\sigma^2}{n}. \end{aligned}$$

# 표본 평균의 성질

- 평균이  $\mu$ 이고 분산이  $\sigma^2$ 인 임의의 모집단으로부터 **random sample**  $X_1, \dots, X_n$ 을 추출하였다고 가정하자. 표본 평균  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 의 성질은 아래와 같다.

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} n\mu = \mu.$$

$$\begin{aligned} \text{Var}(\bar{X}) &= E\left[\{\bar{X} - E(\bar{X})\}^2\right] = E\left[\left\{\frac{1}{n} \sum_{i=1}^n X_i - \mu\right\}^2\right] = E\left[\left\{\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} n\mu\right\}^2\right] \\ &= \frac{1}{n^2} E\left[\left\{\sum_{i=1}^n (X_i - \mu)\right\}^2\right] = \frac{1}{n^2} E\left[\sum_{i=1}^n (X_i - \mu)^2 + \sum_{i \neq j} (X_i - \mu)(X_j - \mu)\right] \\ &= \frac{1}{n^2} \left[\sum_{i=1}^n E(X_i - \mu)^2 + \sum_{i \neq j} E[(X_i - \mu)(X_j - \mu)]\right] \\ &= \frac{1}{n^2} \left[n\sigma^2 + \sum_{i \neq j} [E(X_i - \mu)E(X_j - \mu)]\right] = \frac{\sigma^2}{n}. \end{aligned}$$

⇒ 표본 평균  $\bar{X}$ 은 샘플 숫자가 커질수록 모집단의 평균  $\mu$ 에 가까워진다.

# 표본평균의 성질

```
In [2]: mu, sigma=0,1
```

```
In [3]: np.random.normal(loc=mu, scale=sigma)
```

```
Out[3]: 0.5331692716674414
```

```
In [4]: X=np.random.normal(loc=mu, scale=sigma, size=10000)
```

```
In [5]: X #data
```

```
Out[5]: array([ 0.71269468, -1.23367117,  1.22896926, ...,  2.10196696,  
               -1.01883226,  1.13204636])
```

$$\bar{X}$$

```
In [6]: X.mean()
```


```
Out[6]: 0.0024860210670137267
```

# 표본평균의 성질

```
In [7]: means=[np.mean(np.random.normal(loc=mu, scale=sigma,size=100)) for i in range(1000)]
```

```
In [8]: plt.hist(means)
```

```
Out [8]: (array([ 3., 24., 82., 160., 234., 217., 171., 73., 28., 8.]),
array([-0.31337143, -0.25135704, -0.18934264, -0.12732824, -0.06531385,
       -0.00329945,  0.05871495,  0.12072934,  0.18274374,  0.24475814,
        0.30677254]),
<BarContainer object of 10 artists>)
```



$$\bar{X} \sim \mathcal{N}(\mu, \frac{\sigma^2}{N})$$

```
In [9]: np.mean(means)
```

```
Out [9]: -0.002006202496045791
```

```
In [10]: np.var(means) # close to 0.01 = 1/100
```

```
Out [10]: 0.010147261232552805
```

# 선형회귀분석

# 회귀분석


- 두개 이상의 변수 사이의 관계를 추정하기 위한 통계적 과정.

## Process

- 종속변수 (dependent variable) 와 설명변수 (explanatory variable) 간의 수학적 모형 가정하기.
- 위에서 가정한 수학적 모형을 바탕으로 변수의 관측값(=데이터)을 이용하여 관계 추정하기.
- 추정된 모형이 데이터에 잘 맞는지 테스트 하기. 가정한 수학적 모형이 맞는지 확인하기.



# 회귀분석



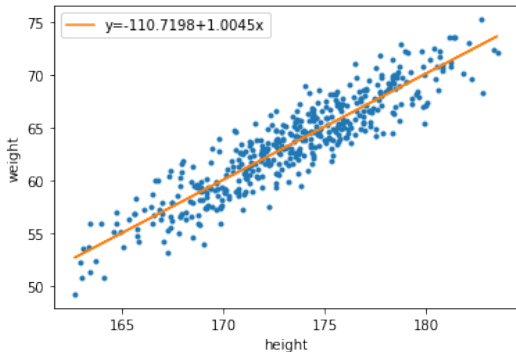
## example

$Y$  (종속 변수) : 몸무게

$X$  (설명 변수) : 키

Relationship:  $Y = f(X)$ .

# 회귀분석



## example

$Y$  (종속 변수) : 몸무게

$X$  (설명 변수) : 키

Relationship:  $Y = f(X)$ .

선형 관계:  $Y = \beta_0 + \beta_1 X$ .

# 선형회귀분석

- 단순 선형 회귀분석:  $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$  ( $\beta_0$ : intercept,  $\beta_1$ : slope)  
 $E(y_i | X = x_i) = \beta_0 + \beta_1 x_i$
- 다중 선형 회귀분석:  $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_p x_{pi} + \varepsilon_i$  ( $\beta_0$ : intercept,  $\beta_1, \cdots, \beta_p$ : slopes)  
 $E(y_i | X_1 = x_{1i}, X_2 = x_{2i}, \cdots, X_p = x_{pi}) = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_p x_{pi}$

계수  $\beta_0, \beta_1, \beta_j$ 의 값을 추정해야 함.

$\varepsilon_1, \varepsilon_2, \cdots, \varepsilon_N$ 은 모두 서로 독립이며  $E(\varepsilon) = 0$ ,  $Var(\varepsilon) = \sigma^2$ 라 가정함.

# 단순 선형 회귀분석: 추정

데이터로부터  $\beta_0$ 와  $\beta_1$ 을 추정하는 방법?  $\Rightarrow$  최소제곱법 (Least Squares Method)

- 최소제곱법

Find  $\beta_0$  and  $\beta_1$  that minimize  $\sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_i)\}^2$

$$\begin{aligned}
 \sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_i)\}^2 &= \sum_{i=1}^N \{y_i^2 - 2y_i(\beta_0 + \beta_1 x_i) + (\beta_0 + \beta_1 x_i)^2\} \\
 &= N\beta_0^2 - 2\beta_0 \sum_{i=1}^N (y_i - \beta_1 x_i) + \sum_{i=1}^N \{y_i^2 - 2\beta_1 x_i y_i + \beta_1^2 x_i^2\} \\
 &= N \left\{ \beta_0^2 - 2\beta_0 \frac{1}{N} \sum_{i=1}^N (y_i - \beta_1 x_i) \right\} + \sum_{i=1}^N (y_i - \beta_1 x_i)^2 \\
 &= N \left\{ \beta_0 - \frac{1}{N} \sum_{i=1}^N (y_i - \beta_1 x_i) \right\}^2 - \frac{1}{N} \left\{ \sum_{i=1}^N (y_i - \beta_1 x_i) \right\}^2 + \sum_{i=1}^N (y_i - \beta_1 x_i)^2
 \end{aligned}$$

# 단순 선형 회귀분석: 추정

Set

$$\hat{\beta}_0 = \frac{1}{N} \sum_{i=1}^N (y_i - \beta_1 x_i) = \bar{y} - \beta_1 \bar{x}.$$

이를 대입하면 아래와 같음.

$$R = -\frac{1}{N} \left\{ \sum_{i=1}^N (y_i - \beta_1 x_i) \right\}^2 + \sum_{i=1}^N (y_i - \beta_1 x_i)^2.$$


$$\begin{aligned} \frac{R}{N} &= -\left\{ \frac{1}{N} \sum_{i=1}^N y_i - \beta_1 \frac{1}{N} \sum_{i=1}^N x_i \right\}^2 + \frac{1}{N} \sum_{i=1}^N (y_i - \beta_1 x_i)^2 \\ &= -\left\{ \bar{y} - \beta_1 \bar{x} \right\}^2 + \frac{1}{N} \sum_{i=1}^N (y_i - \beta_1 x_i)^2 \\ &= -(\bar{y})^2 + 2\beta_1 \bar{x} \bar{y} - \beta_1^2 (\bar{x})^2 + \frac{1}{N} \sum_{i=1}^N y_i^2 - \frac{2}{N} \beta_1 \sum_{i=1}^N x_i y_i + \beta_1^2 \frac{1}{N} \sum_{i=1}^N x_i^2 \\ &= \beta_1^2 \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 - 2\beta_1 \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y}) + C \end{aligned}$$

# 단순 선형 회귀분석: 추정

최소제곱 추정치:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^N (x_i - \bar{x})^2} = \frac{S_{XY}}{S_X^2} = \frac{S_{XY}}{S_{XX}}$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

# 단순 선형 회귀분석: 추정



다른 계산방법: 미분 방정식

손실함수  $\sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_i)\}^2$ 의 기울기를 0으로 두는 미분방정식을 세운다.

$$\frac{\partial}{\partial \beta_0} \sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_i)\}^2 = -2 \sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_i)\} = 0$$

$$\frac{\partial}{\partial \beta_1} \sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_i)\}^2 = -2 \sum_{i=1}^N x_i \{y_i - (\beta_0 + \beta_1 x_i)\} = 0$$

즉, 아래의 연립방정식을 푼다.

$$\begin{cases} N\beta_0 + \sum_{i=1}^N x_i \beta_1 = \sum_{i=1}^N y_i \\ \sum_{i=1}^N x_i \beta_0 + \sum_{i=1}^N x_i^2 \beta_1 = \sum_{i=1}^N x_i y_i \end{cases}$$

# 단순 선형 회귀분석: 추정

행렬로 접근해보자

$$\text{Let } Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} \in \mathbb{R}^{N \times 1}, X = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_N \end{bmatrix} \in \mathbb{R}^{N \times 2}, E = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_N \end{bmatrix} \in \mathbb{R}^{N \times 1}, \text{ and}$$

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} \in \mathbb{R}^{2 \times 1}.$$

$$\Rightarrow Y = X\beta + E,$$

$$\begin{aligned} \sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_i)\}^2 &= (Y - X\beta)^T (Y - X\beta) = (Y^T - (X\beta)^T) (Y - X\beta) \\ &= (Y^T - \beta^T X^T) (Y - X\beta) \quad (\because (AB)^T = B^T A^T) \\ &= Y^T Y - \beta^T X^T Y - Y^T X \beta + \beta^T X^T X \beta \\ &= Y^T Y - 2Y^T X \beta + \beta^T X^T X \beta \end{aligned}$$



# 단순 선형 회귀분석: 추정

- 손실함수:

$$L(\beta) = Y^T Y - 2Y^T X\beta + \beta^T X^T X\beta$$

- 손실함수의 편미분:

$$\frac{\partial}{\partial \beta} L(\beta) = \left[ \begin{array}{c} \frac{\partial}{\partial \beta_0} L(\beta) \\ \frac{\partial}{\partial \beta_1} L(\beta) \end{array} \right] = -2X^T Y + 2X^T X\beta$$

- 최소제곱 추정치:

$$X^T X\beta = X^T Y \text{의 해:}$$

$$(X^T X)^{-1} X^T X\beta = (X^T X)^{-1} X^T Y$$

$$I\beta = (X^T X)^{-1} X^T Y$$

$$\Rightarrow \hat{\beta} = (X^T X)^{-1} X^T Y$$

# 기울기 강하(Gradient Descent)

기울기 강하 방법: 선형회귀분석에서는 손실함수를 최소화하는  $\beta$  값을 한번에 찾을 수 있지만 딥러닝에서는 그러지 못 함. 이때, 최적의 계수  $\beta$  값을 찾을 때 손실함수의 기울기의 반대방향으로  $\beta$  값을 조금씩 이동하면서 찾아나감. (즉, 기울기 강하 방법은 반복적인 과정을 통해 추정치를 도출함.)

- 손실함수:

$$L(\beta) = Y^T Y - 2Y^T X\beta + \beta^T X^T X\beta$$

- 손실함수의 편미분:

$$\frac{\partial}{\partial \beta} L(\beta) = \left[ \begin{array}{c} \frac{\partial}{\partial \beta_0} L(\beta) \\ \frac{\partial}{\partial \beta_1} L(\beta) \end{array} \right] = -2X^T Y + 2X^T X\beta$$

- 기울기 강하 (Gradient Descent) : 편미분(기울기) 반대방향으로의 이동

$$\begin{aligned} \hat{\beta}_{t+1} &= \hat{\beta}_t - \gamma \left. \frac{\partial}{\partial \beta} L(\beta) \right|_{\beta=\hat{\beta}_t} \\ &= \hat{\beta}_t - \gamma \left\{ -2X^T Y + 2X^T X\hat{\beta}_t \right\} \end{aligned}$$

( $\gamma > 0$  를 학습률이라 함.)

# 기울기 강하(Gradient Descent)

- $f(x) \in \mathbb{R}$ 가 벡터  $x \in \mathbb{R}^d$ 의 함수라 하자.
- 함수의 편미분은 다음과 같다.

$$\frac{\partial}{\partial x_1} f(x), \frac{\partial}{\partial x_2} f(x), \dots, \frac{\partial}{\partial x_d} f(x)$$

- (임의의 유닛 벡터  $u$ 에 대한) 방향도함수(Directional derivative) =  $u$ 의 방향으로 변화하는 정도

$$\begin{aligned} D_u f(a) &= \left[ \frac{\partial}{\partial x} f(x) \Big|_{x=a} \right]^T u \\ &= \left\| \frac{\partial}{\partial x} f(x) \Big|_{x=a} \right\| \|u\| \cos\theta \end{aligned}$$

- $D_u f(a)$ 는  $\theta = 0^\circ$ 일때 가장 크고  $\theta = 180^\circ$ 일때 가장 작음.

## 다중 선형 회귀분석: 추정

$$\text{Let } Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} \in \mathbb{R}^{N \times 1}, X = \begin{bmatrix} 1 & x_{11} & x_{21} & \cdots & x_{p1} \\ 1 & x_{12} & x_{22} & \cdots & x_{p2} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{1N} & x_{2N} & \cdots & x_{pN} \end{bmatrix} \in \mathbb{R}^{N \times (p+1)},$$

$$E = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_N \end{bmatrix} \in \mathbb{R}^{N \times 1}, \text{ and } \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix} \in \mathbb{R}^{(p+1) \times 1}.$$

$$\Rightarrow Y = X\beta + E,$$

$$\begin{aligned} \sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_p x_{pi})\}^2 &= (Y - X\beta)^T (Y - X\beta) \\ &= Y^T Y - 2Y^T X\beta + \beta^T X^T X\beta \end{aligned}$$

# 다중 선형 회귀분석: 추정

최소제곱추정치는  $X^T X \beta = X^T Y$ 의 해다.

$$\begin{aligned}
 X^T X &= \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_{11} & x_{12} & \cdots & x_{1N} \\ x_{21} & x_{22} & \cdots & x_{2N} \\ \vdots & \vdots & \vdots & \vdots \\ x_{p1} & x_{p2} & \cdots & x_{pN} \end{bmatrix} \begin{bmatrix} 1 & x_{11} & x_{21} & \cdots & x_{p1} \\ 1 & x_{12} & x_{22} & \cdots & x_{p2} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{1N} & x_{2N} & \cdots & x_{pN} \end{bmatrix} \\
 &= \begin{bmatrix} N & \sum_i x_{1i} & \sum_i x_{2i} & \cdots & \sum_i x_{pi} \\ \sum_i x_{1i} & \sum_i x_{1i}^2 & \sum_i x_{1i} x_{2i} & \cdots & \sum_i x_{1i} x_{pi} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \sum_i x_{pi} & \sum_i x_{1i} x_{pi} & \sum_i x_{2i} x_{pi} & \cdots & \sum_i x_{pi}^2 \end{bmatrix} \in \mathbb{R}^{(p+1) \times (p+1)}
 \end{aligned}$$

$$\begin{aligned}
 X^T Y &= \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_{11} & x_{12} & \cdots & x_{1N} \\ x_{21} & x_{22} & \cdots & x_{2N} \\ \vdots & \vdots & \vdots & \vdots \\ x_{p1} & x_{p2} & \cdots & x_{pN} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} \sum_i y_i \\ \sum_i x_{1i} y_i \\ \sum_i x_{2i} y_i \\ \vdots \\ \sum_i x_{pi} y_i \end{bmatrix} \in \mathbb{R}^{(p+1) \times 1}
 \end{aligned}$$

# 다중 선형 회귀분석: 추정

$$X^T X \beta = X^T Y \Leftrightarrow:$$

$$\begin{array}{ccccccc}
 \beta_0 N & + & \beta_1 \sum_i x_{1i} & + & \beta_2 \sum_i x_{2i} & + & \cdots + \beta_p \sum_i x_{pi} & = & \sum_i y_i \\
 \beta_0 \sum_i x_{1i} & + & \beta_1 \sum_i x_{1i}^2 & + & \beta_2 \sum_i x_{1i} x_{2i} & + & \cdots + \beta_p \sum_i x_{1i} x_{pi} & = & \sum_i x_{1i} y_i \\
 \vdots & & \vdots & & \vdots & & \vdots & & \vdots \\
 \beta_0 \sum_i x_{pi} & + & \beta_1 \sum_i x_{1i} x_{pi} & + & \beta_2 \sum_i x_{2i} x_{pi} & + & \cdots + \beta_p \sum_i x_{pi}^2 & = & \sum_i x_{pi} y_i
 \end{array}$$

만약  $(X^T X)^{-1}$ 가 존재하면,

$$\hat{\beta} = (X^T X)^{-1} X^T Y.$$

# 기울기 강하(Gradient Descent)

- 손실함수:

$$L(\beta) = \sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi})\}^2 = Y^T Y - 2Y^T X\beta + \beta^T X^T X\beta$$

- 손실함수의 편미분:

$$\frac{\partial}{\partial \beta} L(\beta) = \begin{bmatrix} \frac{\partial}{\partial \beta_0} L(\beta) \\ \frac{\partial}{\partial \beta_1} L(\beta) \\ \vdots \\ \frac{\partial}{\partial \beta_p} L(\beta) \end{bmatrix} = \begin{bmatrix} -2 \sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi})\} \\ -2x_{1i} \sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi})\} \\ \vdots \\ -2x_{pi} \sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi})\} \end{bmatrix}$$

$$\frac{\partial}{\partial \beta} L(\beta) = -2X^T Y + 2X^T X\beta = -2X^T (Y - X\beta)$$

- 기울기 강하 (Gradient Descent) : 편미분(기울기) 반대방향으로의 이동

# 최대가능도 추정

- 손실함수:

$$L(\beta) = \sum_{i=1}^N \{y_i - (\beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi})\}^2 = Y^T Y - 2Y^T X\beta + \beta^T X^T X\beta$$

- 위의 식을 손실함수로 쓰는 근거?  $\Rightarrow$  최대가능도 (Maximum Likelihood) 추정치를 도출하기 때문에!



# 최대가능도 (Maximum Likelihood) 방법

- 가능도 함수(Likelihood): 데이터의 확률분포를 모수( $\beta$ )의 함수로 표현한 것.

예) 선형회귀분석 문제를 다시 생각해보자.

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_p x_{pi} + \varepsilon_i$$

여기서 확률 변수  $\varepsilon_i$ 가 독립이며, 정규분포  $\mathcal{N}(0, \sigma^2)$ 을 따른다고 가정하자.  
즉,  $y_i \sim \mathcal{N}(\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_p x_{pi}, \sigma^2)$  이며 확률밀도함수는

$$p(y_i) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \left( \frac{y_i - \beta_0 - \beta_1 x_{1i} - \cdots - \beta_p x_{pi}}{\sigma} \right)^2}$$

또,  $y_1, y_2, \dots, y_N$ 의 결합 확률밀도함수는

$$p(y_1, y_2, \dots, y_N) = \prod_{i=1}^N p(y_i) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \left( \frac{y_i - \beta_0 - \beta_1 x_{1i} - \cdots - \beta_p x_{pi}}{\sigma} \right)^2}$$

$$\Rightarrow \text{Likelihood}(\beta) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \left( \frac{y_i - \beta_0 - \beta_1 x_{1i} - \cdots - \beta_p x_{pi}}{\sigma} \right)^2}$$

## 최대가능도 (Maximum Likelihood) 추정치

- 최대가능도 추정치 (Maximum Likelihood Estimate; MLE): 가능도 함수를 최대로 하는 모수의 값.

예) 선형회귀분석 문제의 MLE 구하기

$Likelihood(\beta)$  를 최대로 하는  $\beta$  값과  $\log Likelihood(\beta)$  를 최대로 하는  $\beta$  값은 동일하므로,  $\log Likelihood(\beta)$ 를 구해보면 아래와 같다:

$$\log Likelihood(\beta) = \sum_{i=1}^N \left\{ \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{2} \left( \frac{y_i - \beta_0 - \beta_1 x_{1i} - \cdots - \beta_p x_{pi}}{\sigma} \right)^2 \right\}$$

$\log Likelihood(\beta)$ 를 최대로 하는  $\beta$  값은

$L(\beta) = \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_{1i} - \cdots - \beta_p x_{pi})^2$ 를 가장 작게 하는  
최소제곱추정치와 동일함을 알 수 있다!

# 최대가능도 (Maximum Likelihood) 추정치

- 최대가능도 추정치 (Maximum Likelihood Estimate) 를 사용하는 이유
  - ① 데이터 개수  $N$ 이 커지면 추정치가 실제값으로 확률 수렴(consistent)한다.
  - ② 점근적으로 효율적인 (asymptotically efficient) 추정치다.

# 로지스틱 회귀분석

# 로지스틱 회귀분석


- 로지스틱 회귀분석 문제:

$$y_i \sim \text{Ber}(\pi(x_i)), \quad \pi(x_i) = \frac{\exp(\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_p x_{pi})}{1 + \exp(\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_p x_{pi})}$$

즉,  $y_i$ 는 0과 1중 하나의 값을 가지는 이항 확률 변수이며

$$P(y_i = 1|x_i) = \pi(x_i), \quad P(y_i = 0|x_i) = 1 - \pi(x_i)$$

이다.



# 로지스틱 회귀분석

- 이때  $y_i$ 의 확률 질량 함수는

$$p(y_i|x_i) = \pi(x_i)^{y_i}(1 - \pi(x_i))^{1-y_i}$$

이며  $y_1, y_2, \dots, y_N$  들이 독립이라고 가정하면 결합 확률 질량 함수는

$$p(y_1, \dots, y_N | x_1, \dots, x_N) = \prod_{i=1}^N p(y_i | x_i) = \prod_{i=1}^N \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i}$$

$$\Rightarrow \text{Likelihood}(\beta) = \prod_{i=1}^N \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i}$$


$$\Rightarrow \log \text{Likelihood}(\beta) = \sum_{i=1}^N \{y_i \log \pi(x_i) + (1 - y_i) \log(1 - \pi(x_i))\}$$

# 로지스틱 회귀분석

- 기울기 강하 등의 방법을 통해  $\log \text{Likelihood}(\beta)$ 를 최대로 하는  $\beta$ 의 값을 찾을 수 있다.
- $-\log \text{Likelihood}(\beta)$ 를 교차 엔트로피 (cross-entropy) 손실함수라고 부르기도 한다.
- $-\log \text{Likelihood}(\beta)$ 의 편미분은?

퀴즈!

# 로지스틱 회귀분석



**Figure:** Graph of Negative log likelihood (ref: Nicolo Cosimo Albanese, "Negative log-partial likelihood of the Cox model with local optimum", towardsdatascience, Published date: Dec 10, 2022, <https://towardsdatascience.com/survival-analysis-optimize-the-partial-likelihood-of-the-cox-model-b56b8f112401>)